Sujet PRED 2026-27

Graph Transformer pour la Classification Multilabel de Molécules Odorantes

GUILLET FABRICE, LS2N, France
VILLIERE ANGELIQUE, Oniris Nantes, France

Cadre de l'étude

L'équipe « Flaveur/MAPS2 » du laboratoire de biochimie GPEA à Oniris est spécialisée dans l'étude des arômes des aliments par olfactométrie. L'olfactométrie combine l'analyse chimique et la perception humaine d'un juge entraîné (un *nez*), afin d'identifier les odeurs des molécules odorantes constituant un arôme (voir video et [0]). Reproduire cette identification des odeurs des molécules à l'aide de modèles d'IA se heurte (1) à la faible disponibilité (~5000 molécules) et (2) à la forte variabilité (du nez humain, i. E. physiologique, anosmie, culturel, représentation mentale des odeurs) des données disponibles.
De nombreux travaux proposent d'apprendre ces modèles (apprentissage multilabel); en particulier avec [1] des modèles de réseaux de neurones graphiques (*Graph Neural Network* - GNN), les molécules pouvant être représentées par des graphes. Cependant, ces GNN sont basés sur la convolution de graphes et souffrent de ses limites, telle que sa forte myopie des voisinages éloignés d'un sommet du graphe (i.e. les atomes éloignés au sein d'une molécule). En revanche, le mécanisme d'attention présent dans les transformeurs de séquences textuelles [2] des LLM n'a pas cette limite de distance entre les mots, puisqu'ils recherchent les dépendances entre mots dans un même contexte. Les transformeurs de graphes [3,4] proposent d'adapter le mécanisme d'attention aux données non séquentielles que sont les graphes.

Objectifs

Ce travail consistera à expérimenter l'usage du *transformeur de graphes (graph transformer) UNI_MOL* proposé dans l'article [5] et son dépot git.
Après un bref état de l'art autour de cette référence ainsi que des résultats de validation des modèles comparables, il faudra construire, apprendre et évaluer un classifieur multi-label d'odeurs à partir de molécules, basée sur *UNI-MOL2.* A cette fin on pourra s'inspirer du modèle de *prédiction de propriétés* d'uni-mol et l'adapter à notre problème en le combinant avec un décodeur multi-label type MLP. Plusieurs enjeux se présenteront éventuellement : (1) le choix du modèle de transformer graphique, (2) l'intégration de la tâche de classification multi-label (décodeur), (3) le choix des données d'apprentissage (4) leur transformation en graphe et l'encodage des attributs du graphes, (5) le mode d'apprentissage de ce graph (GSSL, fine tuning, …), (6) le rééquilibrage des données, (7) l'évaluation des performances du modèle et la comparaison des résultats avec les modèles comparable.

Travail demandé

Les étapes prévisionnelles sont les suivantes :

- Etat de l'art succinct (publications, ressources et codes) autour de UNI-MOL sur les transformeurs de graphes et leur application aux molécules (cf [1,7,9,10]), incluant éventuellement une étude comparative (avantages/inconvénients) relativement à UNI-MOL.
- Récupération des résultats de validation (AUROC, F1,...) annoncés dans les articles des approches baseline (QSOR [1], openPOM [7], …) ;
- Choix du jeux de données multi-labels (molécules+odeurs), de préférence celles du git OPEN-POM : Curated GoodScents-Leffingwell dataset (GS-LF) ?
- Choix et encodage/featurization des données : transformation des molécules en graphes via code smile, encodage des attributs (sommets, arêtes, global) selon le transformeur UNI-MOL;

- L'intégration de la tâche de classification multi-label (décodeur) au transformeur : modalité d'apprentissage (fine tuning ?), fonction de coût (loss BCE ?); échantillonnage, rééquilibrage et lots (StratifyedKFold() ?) ; critère d'évaluation multilabel (micro/macro F1 AUC?);
- Evaluation de la solution proposée et comparaison aux résultats des modèles comparables (cf biblio);
- Explication du fonctionnement du modèle sur quelques molécules
- Améliorations

Compétences et outils

Langage : python
Outils : pytorch geometric, scikit learn, RDkit, pubChemPy, NistChemPy gitlab; deepchem, OpenPOM…

Références

[0] Meierhenrich, U. J., Golebiowski, J., Fernandez, X., & Cabrol-Bass, D. (2005). De la molécule à l'odeur. *L'actualité chimique*, *289*(29), 29-40. pdf

Baseline :
[1] Sanchez-Lengeling, B., Wei, J. N., Lee, B. K., Gerkin, R. C., Aspuru-Guzik, A., & Wiltschko, A. B. (2019). Machine learning for scent: Learning generalizable perceptual representations of small molecules. *arXiv preprint arXiv:1910.10685*. arxiv *pdf* and also ai.googleblog
[8] Git OpenPOM : https://github.com/BioMachineLearning/openpom

Graph Transformers :
[2] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. Advances in neural information processing systems, 30. pdf
[3] Shehzad, A., Xia, F., Abid, S., Peng, C., Yu, S., Zhang, D., & Verspoor, K. (2024). Graph transformers: A survey. *arXiv preprint arXiv:2407.09777*. arxiv
[4] Rong, Y., Bian, Kim, J., Nguyen, D., Min, S., Cho, S., Lee, M., Lee, H., & Hong, S. (2022). Pure transformers are powerful graph learners. *Advances in Neural Information Processing Systems*, *35*, 14582-14595. Arxiv

Main paper :
[5] Ji, X., Wang, Z., Gao, Z., Zheng, H., Zhang, L., & Ke, G. (2024). Exploring molecular pretraining model at scale. *Advances in Neural Information Processing Systems*, *37*, 46956-46978
neurips github

Related works (to be completed) :
[9] Sharma, M., Balaji, S., Parma, V., & Kumar, R. (**2026**). **GraphNOSE**: A Graph Transformer in Olfaction. ***arXiv preprint*** *arXiv:2609.05694*. Arxiv
[10] Zhang, S., & Lapkin, A. A. (**2026**). Enhancing molecular property prediction of transformer models with dual graph representation. *Nature Communications*. nature

Others :
[6] Y., Xu, T., Xie, W., Wei, Y., Huang, W., & Huang, J. (2020). Self-supervised graph transformer on large-scale molecular data. *Advances in neural information processing systems*, *33*, 12559-12571. neurips => GROVER
[7] Liu, G., Xu, J., Luo, T., & Jiang, M. (2024). Graph diffusion transformers for multi-conditional molecular generation. *Advances in Neural Information Processing Systems*, *37*, 8065-8092. arxiv